Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №3
по дисциплине
«Методы машинного обучения»
на тему
«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Выполнил:
студент группы ИУ5-23М
Иванников А. В.

Москва — 2019 г.

1. Описание задания

Цель лабораторной работы: изучение способов предварительной обработки данных для дальнейшего формирования моделей

2. Задание

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:

- обработку пропусков в данных;
- кодирование категориальных признаков;
- масштабирование данных.

3. Ход выполнения лабораторной работы

[0]:
```
from google.colab import drive, files
drive.mount('/content/drive')
```

Обновим seaborn до необходимой версии:

[0]:
```
!pip install -U seaborn
```

Датасет представляет из себя проекты kickstarter, которые были опубликованы в январе 2018 года. Он содержит в себе данные о количестве требуемых денег, количестве полученных денег на момент февраля 2018 года.

[0]:
```
from google.colab import files
import os
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
os.listdir()
data = pd.read_csv('drive/My Drive/Files/dataset/master.csv', sep=",")
```

4. Обработка пропущенных данных

4.1. Нахождение колонок с пропущенными данными

[4]:
```
total_count = data.shape[0]
num_cols = []
for col in data.columns:
    # Количество пустых значений
```

```
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {},
↪{}%.'.format(col, dt, temp_null_count, temp_perc))
```

```
Колонка HDI for year. Тип данных float64. Количество пустых значений 19456,
69.94%.
```

[5]:
```
data_num = data[num_cols]
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

```
/usr/local/lib/python3.6/dist-packages/numpy/lib/function_base.py:780:
RuntimeWarning: invalid value encountered in greater_equal
  keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/function_base.py:781:
RuntimeWarning: invalid value encountered in less_equal
  keep &= (tmp_a <= last_edge)
```

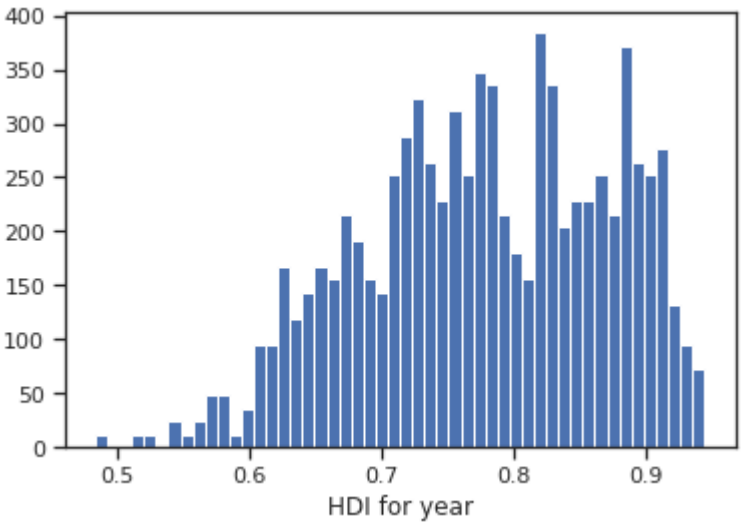

4.2. Обработка пропущенных данных

4.2.1. Простые стратегии

[6]:
```
# Удаление колонок, содержащих пустые значения
data_new_1 = data.dropna(axis=1, how='any')
(data.shape, data_new_1.shape)
```

[6]:
```
((27820, 12), (27820, 11))
```

[7]:
```
# Удаление строк, содержащих пустые значения
data_new_2 = data.dropna(axis=0, how='any')
(data.shape, data_new_2.shape)
```

[7]:
```
((27820, 12), (8364, 12))
```

[8]:
```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator

flt_index = data[data['HDI for year'].isnull()].index
data[data.index.isin(flt_index)][0:10]
```

[8]:

	country	year	sex	age	suicides_no	population	suicides/100k pop	country-year	HDI for year	gdp_for_year ($)	gdp_per_capita ($)	generation
0	Albania	1987	male	15-24 years	21	312900	6.71	Albania1987	NaN	2,156,624,900	796	Generation X
1	Albania	1987	male	35-54 years	16	308000	5.19	Albania1987	NaN	2,156,624,900	796	Silent
2	Albania	1987	female	15-24 years	14	289700	4.83	Albania1987	NaN	2,156,624,900	796	Generation X
3	Albania	1987	male	75+ years	1	21800	4.59	Albania1987	NaN	2,156,624,900	796	G.I. Generation
4	Albania	1987	male	25-34 years	9	274300	3.28	Albania1987	NaN	2,156,624,900	796	Boomers
5	Albania	1987	female	75+ years	1	35600	2.81	Albania1987	NaN	2,156,624,900	796	G.I. Generation
6	Albania	1987	female	35-54 years	6	278800	2.15	Albania1987	NaN	2,156,624,900	796	Silent
7	Albania	1987	female	25-34 years	4	257200	1.56	Albania1987	NaN	2,156,624,900	796	Boomers
8	Albania	1987	male	55-74 years	1	137500	0.73	Albania1987	NaN	2,156,624,900	796	G.I. Generation
9	Albania	1987	female	5-14 years	0	311000	0.00	Albania1987	NaN	2,156,624,900	796	Generation X

[9]:
```
data_num_MasVnrArea = data_num[['HDI for year']]
data_num_MasVnrArea.head()
```

[9]:
```
   HDI for year
0           NaN
1           NaN
2           NaN
3           NaN
4           NaN
```

4.2.2. Импьютация

[10]:
```
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_MasVnrArea)
mask_missing_values_only
```

[10]:
```
array([[ True],
       [ True],
       [ True],
       …,
       [False],
       [False],
       [False]])
```

[0]:
```
strategies=['mean', 'median','most_frequent']
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_num_MasVnrArea)
    return data_num_imp[mask_missing_values_only]
```

[12]:
```
strategies[0], test_num_impute(strategies[0])
```

[12]:
```
('mean',
 array([0.77660115, 0.77660115, 0.77660115, …, 0.77660115, 0.77660115,
        0.77660115]))
```

[13]:
```
strategies[1], test_num_impute(strategies[1])
```

[13]:
```
('median', array([0.779, 0.779, 0.779, …, 0.779, 0.779, 0.779]))
```

[14]:
```
strategies[2], test_num_impute(strategies[2])
```

[14]:
```
('most_frequent', array([0.713, 0.713, 0.713, …, 0.713, 0.713, 0.713]))
```

5. Преобразование категориальных данных

5.1. Кодирование целочисленными значениями

[0]:
```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

[16]:
```
cat_temp_data = data[['generation']]
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
cat_enc = pd.DataFrame({'generation':data_imp2.T[0]})
cat_enc[0:10]
```

[16]:
```
        generation
0     Generation X
1           Silent
2     Generation X
3  G.I. Generation
4          Boomers
5  G.I. Generation
6           Silent
7          Boomers
8  G.I. Generation
9     Generation X
```

[17]:
```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['generation'])
cat_enc['generation'].unique()
```

[17]:
```
array(['Generation X', 'Silent', 'G.I. Generation', 'Boomers',
       'Millenials', 'Generation Z'], dtype=object)
```

[18]:
```
np.unique(cat_enc_le)
```

[18]:
```
array([0, 1, 2, 3, 4, 5])
```

[19]:
```
le.inverse_transform([0])
```

[19]:
```
array(['Boomers'], dtype=object)
```

5.2. One-hot encoding¶

[20]:
```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['generation']])
cat_enc.shape
```

[20]:
```
(27820, 1)
```

[21]:
```
cat_enc_ohe.todense()[0:10]
```

[21]:
```
matrix([[0., 0., 1., 0., 0., 0.],
        [0., 0., 0., 0., 0., 1.],
        [0., 0., 1., 0., 0., 0.],
        [0., 1., 0., 0., 0., 0.],
        [1., 0., 0., 0., 0., 0.],
        [0., 1., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 1.],
        [1., 0., 0., 0., 0., 0.],
```

```
       [0., 1., 0., 0., 0., 0.],
       [0., 0., 1., 0., 0., 0.]])
```

6. Масштабирование данных

6.1. MinMax масштабирование

[22]:
```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer

sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['gdp_per_capita ($)']])

plt.hist(data['gdp_per_capita ($)'], 30)
plt.xlabel('GDP per capita')
plt.show()
```

```
/usr/local/lib/python3.6/dist-packages/sklearn/preprocessing/data.py:334:
DataConversionWarning: Data with input dtype int64 were all converted to
 ↪float64
by MinMaxScaler.
  return self.partial_fit(X, y)
```

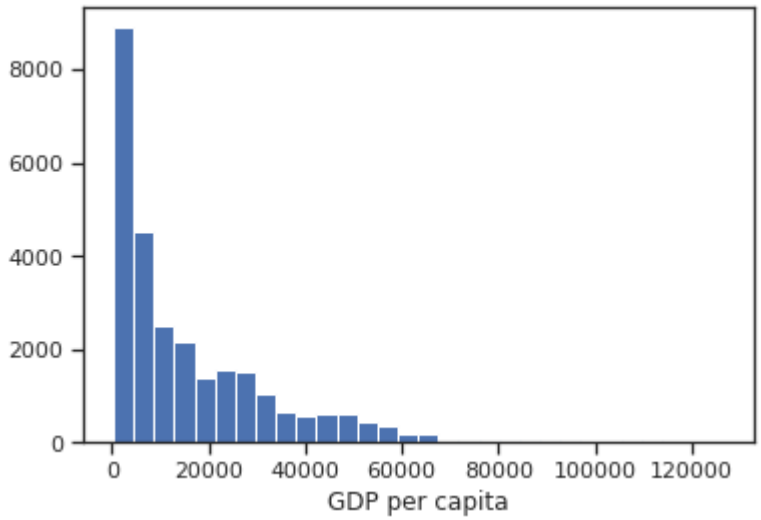

[23]:
```
plt.hist(sc1_data, 30)
plt.xlabel('GDP per capita')
plt.show()
```

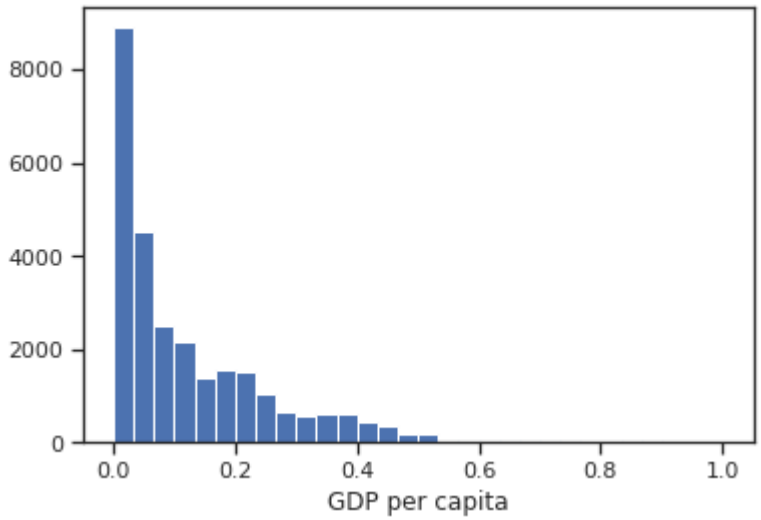

6.2. Масштабирование данных на основе Z-оценки - StandardScaler

[24]:
```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['gdp_per_capita ($)']])

plt.hist(sc2_data, 30)
plt.xlabel('GDP per capita')
plt.show()
```

```
/usr/local/lib/python3.6/dist-packages/sklearn/preprocessing/data.py:645:
DataConversionWarning: Data with input dtype int64 were all converted to
 ↪float64
by StandardScaler.
  return self.partial_fit(X, y)
/usr/local/lib/python3.6/dist-packages/sklearn/base.py:464:
DataConversionWarning: Data with input dtype int64 were all converted to
 ↪float64
by StandardScaler.
  return self.fit(X, **fit_params).transform(X)
```

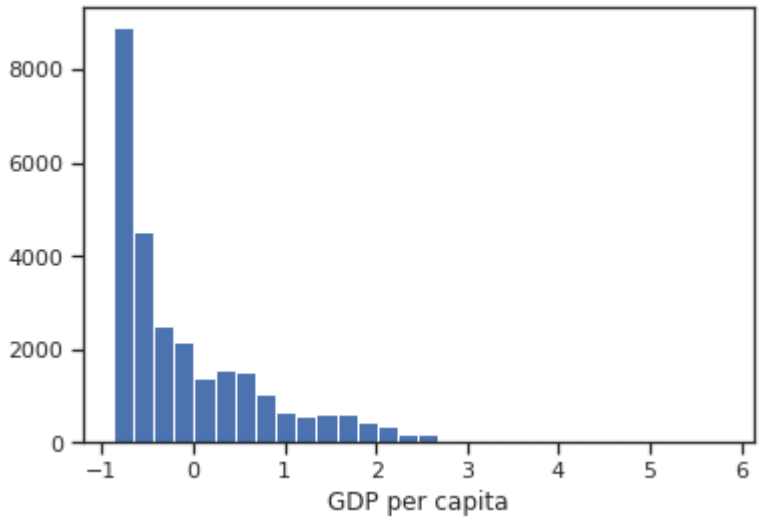

[25]:
```
sc3 = Normalizer()
sc3_data = sc3.fit_transform(data[['gdp_per_capita ($)']])

plt.hist(sc3_data, 30)
plt.xlabel('GDP per capita')
plt.show()
```